

Spectral Clustering: Implementazione e Analisi Comparativa di Metodi Normalizzati e Non Normalizzati

Giuseppe Prudente

Dipartimento di Ingegneria
Corso di Laurea in Ingegneria Informatica
Università degli Studi di Perugia
Perugia, Italia
giuseppe.prudente@studenti.unipg.it

Abstract—In questo progetto viene sviluppata un'implementazione modulare in Python dell'algoritmo di Spectral Clustering, con l'obiettivo di confrontare tre differenti varianti: la versione non normalizzata e due versioni normalizzate, proposte da Shi & Malik e da Ng-Jordan-Weiss. Il workflow prevede la generazione dei dati, la costruzione della matrice di similarità tramite kernel gaussiano, la definizione della matrice dei gradi e della matrice di adiacenza pesata, seguita dalla creazione di un grafo k-nearest neighbors e dal calcolo delle matrici Laplaciane associate. Le soluzioni dei problemi agli autovalori consentono di ottenere rappresentazioni a bassa dimensionalità (embedding spettrale), sulle quali viene applicato l'algoritmo k-means per l'individuazione dei cluster. La scelta del numero ottimale di cluster viene supportata dall'analisi del gap spettrale tra gli autovalori. Il sistema include inoltre strumenti avanzati di visualizzazione e metriche di valutazione, permettendo un'analisi sia qualitativa sia quantitativa delle prestazioni. Il confronto evidenzia le differenze tra le varianti considerate e il ruolo della normalizzazione nel migliorare la separabilità e la stabilità dei cluster.

Index Terms—Spectral Clustering; Graph Laplacian; Graph; Python; Clustering; Similarity Matrix

I. INTRODUZIONE

Il problema del clustering consiste nella suddivisione di un insieme di dati in gruppi omogenei, massimizzando la similarità intra-cluster e minimizzando quella inter-cluster. Tra le diverse metodologie proposte in letteratura, gli approcci spettrali hanno acquisito crescente rilevanza grazie alla loro capacità di catturare la struttura globale dei dati attraverso una rappresentazione grafica. Nel Spectral Clustering, i dati vengono modellati come un grafo pesato, in cui i nodi rappresentano le osservazioni e gli archi sono definiti a partire da una funzione di similarità. La struttura del grafo è quindi codificata tramite la matrice di adiacenza e la matrice dei gradi, dalle quali si ricavano diverse forme di Laplaciana. Il problema di clustering viene così ricondotto allo studio delle proprietà spettrali di tali operatori, ed in particolare allo studio degli autovalori e autovettori ad essi associati. In questo lavoro vengono considerate tre diverse formulazioni dell'approccio spettrale: la versione non normalizzata e due

versioni normalizzate, basate rispettivamente sulla Laplaciana generalizzata e sulla Laplaciana simmetrica normalizzata. Tali varianti differiscono per le proprietà teoriche degli operatori coinvolti e per il modo in cui la struttura del grafo viene normalizzata rispetto ai gradi dei nodi. L'obiettivo è analizzare il comportamento di queste formulazioni da un punto di vista sia teorico sia computazionale, evidenziando il ruolo della normalizzazione e l'impatto delle diverse scelte nella costruzione del grafo e nella definizione dello spazio spettrale.

II. MATERIALI E METODI

In questo studio sono stati implementati tre algoritmi di Spectral Clustering in ambiente Python, utilizzando le librerie NumPy, NetworkX, SciPy e Matplotlib per la gestione numerica, la rappresentazione dei grafi, il calcolo spettrale e la visualizzazione dei risultati. Il processo metodologico è stato articolato in quattro fasi principali. In primo luogo, è stato generato un segnale casuale discreto su un insieme di $n=25$ nodi, con valori interi compresi tra 0 e 99, al fine di simulare dati da clusterizzare. Successivamente è stata calcolata la matrice di similarità S mediante kernel gaussiano, definita come $S_{ij} = \exp(-\frac{(x_i - x_j)^2}{2\sigma^2})$ con parametro di scala $\sigma = 60$, in modo da quantificare la vicinanza tra i nodi sulla base della distanza tra i rispettivi valori. A partire da questa matrice è stato costruito un grafo k-nearest neighbors (k-NN) con k variabile, mantenendo per ciascun nodo soltanto i k vicini più simili e successivamente simmetrizzando la matrice di adiacenza per ottenere un grafo non orientato pesato. Infine, sono state calcolate sia la Laplaciana non normalizzata $L = D - W$, sia la Laplaciana normalizzata simmetrica $I - D^{-1/2} W D^{-1/2}$, utilizzate per confrontare tre varianti di Spectral Clustering: il metodo non normalizzato, l'approccio normalizzato di Shi e Malik (2000) e quello di Ng, Jordan e Weiss (2002).

III. STRUMENTI MATEMATICI

A. Grafi di Similarità

Dato un insieme di punti $x_1, \dots, x_n$ e una certa nozione di similarità $s_{ij} \geq 0$ tra tutte le coppie x_i e x_j , l'obiettivo intuitivo del clustering è suddividere i punti dati in diversi

gruppi tali che quelli appartenenti allo stesso gruppo siano simili tra loro, mentre i punti appartenenti a gruppi diversi siano dissimili tra loro.

Un modo efficace per rappresentare il vettore dei dati è attraverso il grafo di similarità $G = (V, E)$. Ogni vertice v_i di questo grafo rappresenta un punto x_i . Due vertici sono connessi se la similarità s_{ij} tra i corrispondenti punti è positiva oppure superiore a una certa soglia, inoltre l'arco è pesato da un coefficiente chiamato s_{ij} .

Il problema del clustering può quindi essere riformulato utilizzando il grafo di similarità: si vuole trovare una partizione del grafo tale che gli archi tra gruppi diversi abbiano pesi molto bassi (il che significa che i punti appartenenti a cluster diversi sono dissimili tra loro) e che gli archi all'interno di uno stesso gruppo abbiano pesi elevati.

B. Tipi di similarità e di grafo

Esistono diversi metodi per trasformare un dato insieme di punti $x_1, \dots, x_n$ con similarità a coppie s_{ij} oppure distanze a coppie d_{ij} , in un grafo $G = (V, E)$.

Quando si costruiscono grafi di similarità, l'obiettivo è modellare le relazioni di vicinato locale tra i punti dati.

1) *The ϵ -neighborhood graph*: In questo caso si connettono tutti i punti le cui distanze a coppie sono minori di ϵ . Poiché le distanze tra tutti i punti connessi sono approssimativamente della stessa scala (al massimo ϵ), assegnare un peso agli archi non aggiungerebbe ulteriori informazioni sui dati al grafo.

Per questo motivo, il grafo di ϵ -intorno viene solitamente considerato come un **grafo non pesato**.

2) *k-nearest neighbor graphs*: In questo caso, l'obiettivo è connettere il vertice v_i con il vertice v_j se v_j appartiene ai k vicini più prossimi di v_i . Tuttavia, questa definizione porta a un grafo orientato, poiché la relazione di vicinato non è simmetrica.

Esistono due modi per rendere questo grafo non orientato. Il primo consiste semplicemente nell'ignorare la direzione degli archi, cioè si connettono v_i e v_j con un arco non orientato se v_i appartiene ai k vicini più prossimi di v_j oppure se v_j appartiene ai k vicini più prossimi di v_i . Il grafo risultante è quello che viene solitamente chiamato **grafo dei k-nearest neighbors**.

La seconda possibilità consiste nel connettere i vertici v_i e v_j solo se sia v_i appartiene ai k vicini più prossimi di v_j sia v_j appartiene ai k vicini più prossimi di v_i . Il grafo risultante è chiamato grafo dei mutual k -nearest neighbors.

In entrambi i casi, dopo aver connesso i vertici appropriati, gli archi vengono pesati in base alla similarità dei loro estremi.

3) *The fully connected graph*: In questo caso si connettono semplicemente tutti i punti che presentano una similarità positiva tra loro, e tutti gli archi vengono pesati con s_{ij} . Poiché il grafo dovrebbe rappresentare le relazioni di vicinato locale, questa costruzione è utile solo se la stessa funzione di similarità modella i vicinati locali.

Un esempio di tale funzione di similarità è la seguente:

$$s(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right),$$

dove il parametro σ controlla l'ampiezza dei vicinati. Questo parametro svolge un ruolo simile a quello del parametro ϵ nel caso precedente.

C. Laplaciana di un Grafo

Lo strumento principale utilizzato per condurre una clusterizzazione spettrale e' la matrice Laplaciana associata ad un grafo. In questa sezione vengono definite due diverse versioni di questa matrice.

Nel seguito della trattazione verterà sempre assunto che G risulti essere un grafo non orientato e pesato con matrice dei pesi W , dove $w_{ij} = w_{ji} \geq 0$. Gli autovalori saranno sempre ordinati in modo crescente, tenendo conto delle molteplicità.

1) *Laplaciana non normalizzata*: La matrice laplaciana non normalizzata del grafo è definita come $L = D - W$.

2) *Laplaciana Normalizzata*: In letteratura esistono due matrici che vengono utilizzate come Laplaciane normalizzate e che possono essere associate ad un grafo. Entrambe sono strettamente collegate tra loro e sono definite come segue:

$$L_{sym} := D^{-1/2} L D^{-1/2} = I - D^{-1/2} W D^{-1/2}$$

$$L_{rw} := D^{-1} L = I - D^{-1} W$$

IV. ALGORITMI DI CLUSTERING SPETTRALI

Nel seguente paragrafo vengono descritti i tre differenti algoritmi utilizzati per la clusterizzazione di uno stesso grafo $G = (V, E)$.

Nella trattazione si assume che i dati siano costituiti da n "punti" $x_1, \dots, x_n$, i quali rappresentano oggetti arbitrari. In prima istanza si misurano le loro similarità a coppie $s_{ij} = s(x_i, x_j)$ tramite una funzione di similarità che sia simmetrica e non negativa, e successivamente si definisce la matrice di similarità corrispondente con $S = (s_{ij})_{i,j=1,\dots,n}$.

A. Clustering Spettrale non normalizzato

L'algoritmo di Spectral Clustering non normalizzato costituisce la formulazione classica del clustering spettrale ed è basato sulle proprietà spettrali della matrice Laplaciana associata al grafo di similarità. Data una matrice di similarità $S \in \mathbb{R}^{n \times n}$ e fissato il numero k di cluster da individuare, il procedimento inizia con la costruzione di un grafo di similarità pesato, in cui ciascun nodo rappresenta un'osservazione e il peso di ciascun arco esprime il grado di affinità tra le coppie di nodi. Da tale rappresentazione si ottiene la matrice di adiacenza pesata W , a partire dalla quale viene definita la matrice dei gradi D , matrice diagonale i cui elementi sono dati da $D_{ii} = \sum_j W_{ij}$.

La Laplaciana non normalizzata associata al grafo viene quindi calcolata come $L = D - W$. Il passo successivo consiste

nel calcolo dei primi k autovettori $u_1, \dots, u_n$ associati ai più piccoli autovalori della matrice L . Tali autovettori vengono disposti come colonne della matrice $U \in R^{n \times k}$, la cui i -esima riga y_i rappresenta una nuova proiezione del nodo i -esimo in uno spazio spettrale a dimensione ridotta. Questa trasformazione consente di evidenziare la struttura intrinseca dei dati e di rendere maggiormente separabili i gruppi presenti nel grafo. Infine, l'algoritmo k -means viene applicato ai vettori riga $(y_i)_{i=1, \dots, n}$ ottenendo una partizione in k cluster $C_1, \dots, C_k$. I cluster finali del problema originario sono quindi definiti come $A_i = \{j | y_j \in C_i\}$, fornendo una suddivisione dei nodi basata sulla connettività globale del grafo piuttosto che sulla sola distanza euclidea nello spazio originale dei dati.

Algorithm 1 Clustering spettrale non Normalizzato

Require: Matrice di Similarita' $S \in R^{n \times n}$, numero k di clusters da costruire.

- 1 Costruire un grafo di similarità. Sia W la sua matrice di adiacenza pesata.
- 2 Calcolare il Laplaciano non normalizzato L .
- 3 Calcolare i primi k autovettori $u_1, \dots, u_k$ di L .
- 4 Sia $U \in R^{n \times k}$ la matrice contenente i vettori $u_1, \dots, u_k$ come colonne.
- 5 Per $i = 1, \dots, n$, sia $y_i \in R^k$ il vettore corrispondente all' i -esima riga di U .
- 6 Clustering dei punti $(y_i)_{i=1, \dots, n}$ in k clusters utilizzando l'algoritmo k -means ed ottenendo così $C_1, \dots, C_k$ clusters.

Output Clusters $A_1, \dots, A_k$ con $A_i = \{j | y_j \in C_i\}$.

B. Clusetring Spettrale Normalizzato Shi & Malik

L'algoritmo di Spectral Clustering normalizzato proposto da Jianbo Shi e Jitendra Malik (2000) introduce una normalizzazione della Laplaciana al fine di gestire in modo più efficace grafi caratterizzati da nodi con gradi molto eterogenei. A partire dalla matrice di similarità $S \in R^{n \times n}$, viene costruito il grafo di similarità pesato e la corrispondente matrice di adiacenza W , da cui si ricava la matrice dei gradi D , definita come $D_{ii} = \sum_j W_{ij}$. La Laplaciana non normalizzata è data da $L = D - W$, ma, a differenza della versione classica, il clustering viene ottenuto risolvendo il problema agli autovalori generalizzato $Lu = \lambda Du$. Gli autovettori associati ai più piccoli autovalori forniscono una rappresentazione spettrale che tiene conto della distribuzione dei gradi nel grafo, evitando che nodi altamente connessi influenzino eccessivamente la partizione finale. I primi k autovettori vengono raccolti nella matrice $U \in R^{n \times k}$, le cui righe rappresentano i punti nello spazio spettrale su cui viene successivamente applicato l'algoritmo k -means. La partizione finale risulta quindi più robusta rispetto alla formulazione non normalizzata, in particolare nei casi in cui i cluster presentano dimensioni o densità differenti, consentendo una migliore approssimazione del criterio di Normalized Cut.

C. Clustering Spettrale Normalizzato Ng, Jordan & Weiss

L'approccio proposto da Andrew Y. Ng, Michael I. Jordan e Yair Weiss (2002) rappresenta una delle formulazioni

Algorithm 2 Clusetring Spettrale Shi & Malik

Require: Matrice di Similarita' $S \in R^{n \times n}$, numero k di clusters da costruire.

- 1 Costruire un grafo di similarità. Sia W la sua matrice di adiacenza pesata.
- 2 Calcolare il Laplaciano non normalizzato L .
- 3 Calcolare i primi k Autovettori $u_1, \dots, u_k$ soluzione dell'equazione $Lu = \lambda Du$.
- 4 Sia $U \in R^{n \times k}$ la matrice contenente i vettori $u_1, \dots, u_k$ come colonne.
- 5 Per $i = 1, \dots, n$, sia $y_i \in R^k$ il vettore corrispondente all' i -esima riga di U .
- 6 Clustering dei punti $(y_i)_{i=1, \dots, n}$ in k clusters utilizzando l'algoritmo k -means ed ottenendo così $C_1, \dots, C_k$ clusters.

Output Clusters $A_1, \dots, A_k$ con $A_i = \{j | y_j \in C_i\}$.

più utilizzate del clustering spettrale normalizzato e si basa sull'impiego della Laplaciana simmetrica normalizzata. Dopo la costruzione del grafo di similarità e della matrice di adiacenza pesata W , viene definita la matrice dei gradi D e successivamente la Laplaciana normalizzata simmetrica come $L_{Sym} = I - D^{-1/2} W D^{-1/2}$, dove I rappresenta la matrice identità. Si calcolano quindi i primi k autovettori associati ai più piccoli autovalori di L_{Sym} , che vengono disposti come colonne della matrice $U \in R^{n \times k}$. A differenza del metodo di Shi e Malik, in questo caso viene eseguita un'ulteriore normalizzazione riga per riga della matrice U , ottenendo una nuova matrice T , in cui ciascun vettore ha norma unitaria. Tale passaggio consente di proiettare i dati su una superficie unitaria, migliorando la separabilità geometrica dei cluster nello spazio spettrale. L'algoritmo k -means viene quindi applicato alle righe della matrice T , producendo la suddivisione finale dei nodi nei cluster $A_1, \dots, A_k$. Questa formulazione risulta particolarmente efficace in presenza di strutture complesse e cluster non linearmente separabili, garantendo elevata stabilità numerica e buone prestazioni applicative.

Algorithm 3 Clustering Spettrale Normalizzato Ng, Jordan & Weiss

Require: Matrice di Similarita' $S \in R^{n \times n}$, numero k di clusters da costruire.

- 1 Costruire un grafo di similarità. Sia W la sua matrice di adiacenza pesata.
- 2 Calcolare il Laplaciano normalizzato L_{sym} .
- 3 Calcolare i primi k Autovettori $u_1, \dots, u_k$ della matrice L_{sym} .
- 4 Sia $U \in R^{n \times k}$ la matrice contenente i vettori $u_1, \dots, u_k$ come colonne.
- 5 Costruire la matrice $T \in R^{n \times k}$ partendo da U , normalizzando ad 1 le righe, così che $t_{ij} = \frac{u_{ij}}{(\sum_k u_{ij}^2)^{\frac{1}{2}}}$.
- 6 Per $i = 1, \dots, n$, sia $y_i \in R^k$ il vettore corrispondente all'iesima riga di T .
- 7 Clustering dei punti $(y_i)_{i=1, \dots, n}$ in k clusters utilizzando l'algoritmo k-means ed ottenendo così $C_1, \dots, C_k$ clusters.

Output Clusters $A_1, \dots, A_k$ con $A_i = \{j | y_j \in C_i\}$.

V. RISULTATI

Gli algoritmi di spectral clustering sono stati implementati e testati su un grafo di similarità costruito a partire da un segnale discreto di 25 nodi, generato mediante distribuzione uniforme nell'intervallo $[0, 100)$. La matrice di similarità (Fig. 1) è stata calcolata utilizzando un kernel gaussiano con parametro $\sigma = 60$, mentre la struttura del grafo è stata determinata mediante l'algoritmo k-nearest neighbors (k-NN) con $k = 4$ numero dei vicini presi in considerazione, ottenendo così la matrice pesata delle adiacenze W (Fig. 2) che porta alla formazione del seguente grafo rappresentato in Fig. 3.

A. Analisi degli spettri

L'analisi degli autovalori ha rivelato comportamenti distinti tra i tre metodi implementati.

Per il metodo non normalizzato, i primi tre autovalori della matrice Laplaciana L sono risultati $\lambda_1 = 0$, $\lambda_2 = 0.0857$ e $\lambda_3 = 0.3959$, con un eigengap significativo tra il terzo e il quarto autovalore, pari a $\Delta\lambda_3 = 1.2751$. (Fig. 4). Questo eigengap pronunciato suggerisce una chiara separabilità in tre cluster, confermando la validità teorica del criterio di selezione del numero ottimale di cluster basato sull'analisi dello spettro.

Per il metodo normalizzato di Shi e Malik (2000), basato sul problema agli autovalori generalizzato $Lu = \lambda Du$, gli autovalori corrispondenti sono stati $\lambda_1 = 0$, $\lambda_2 = 0.0151$ e $\lambda_3 = 0.0719$, con eigengap $\Delta\lambda_3 = 0.2500$.

Analogamente, il metodo di Ng, Jordan e Weiss (2002), applicato alla Laplaciana normalizzata simmetrica L_{sym} , ha prodotto autovalori identici ($\lambda_1 = 0$, $\lambda_2 = 0.0151$ e $\lambda_3 = 0.0719$) con lo stesso eigengap. (Fig. 6).

È interessante notare che, sebbene i metodi normalizzati producano autovalori di scala inferiore rispetto al metodo




Fig. 1. Matrice di Similarita'




Fig. 2. Matrice Pesata delle Adiacenze

Grafo Originale




Fig. 3. Grafo Originale

non normalizzato, l'eigengap relativo risulta comparabile, indicando una robustezza intrinseca nella determinazione del numero di cluster.

B. Confronto delle Prestazioni di Clustering

L'embedding dei nodi nello spazio degli autovettori ha mostrato differenze qualitative tra i tre approcci. Il metodo non normalizzato utilizza direttamente gli autovettori di L , producendo una rappresentazione dove i nodi sono distribuiti senza vincoli di normalizzazione. I metodi normalizzati, invece, operano su spazi metrici differenti: Shi e Malik preservano le componenti degli autovettori generalizzati, mentre Ng, Jordan e Weiss introducono un passo di normalizzazione delle righe che proietta tutti i punti sulla superficie di una sfera unitaria k -dimensionale. Questa normalizzazione geometrica garantisce che la distanza euclidea nello spazio embedded sia invariante rispetto alla scala dei cluster originali, un vantaggio significativo per dataset con cluster di dimensioni variabili.

Si osserva che, limitandosi al problema introdotto in precedenza, in cui viene costruito un grafo costituito da 25 nodi e ciascun nodo è connesso ai suoi $k=4$ vicini più simili, i risultati ottenuti mediante i tre differenti algoritmi di spectral clustering conducono alla medesima partizione del grafo. In questo caso, infatti, sia l'approccio non normalizzato sia le due varianti normalizzate producono una separazione coerente e stabile in tre

cluster distinti, evidenziando come, in presenza di una struttura relativamente semplice e ben definita, le diverse formulazioni dell'algoritmo tendano a convergere verso la stessa soluzione. Tale comportamento è chiaramente osservabile nelle Fig. 7, Fig. 8 e Fig. 9.

Differenze più significative emergono invece quando la struttura del grafo diventa più complessa e il numero delle connessioni aumenta sensibilmente, pur mantenendo invariato il numero ottimale di cluster attesi. Considerando, ad esempio, un grafo composto da 30 nodi, costruito collegando ciascun nodo ai suoi $k=7$ vicini più simili, si osserva che l'aumento della densità delle connessioni rende più difficile l'individuazione di una partizione chiara mediante l'algoritmo di spectral clustering non normalizzato. In particolare, quest'ultimo mostra una maggiore difficoltà nel suddividere correttamente il grafo in tre cluster distinti e interpretabili, come evidenziato in Fig. 10. Al contrario, l'algoritmo normalizzato di Shi e Malik riesce a preservare una separazione più accurata e coerente con la struttura intrinseca dei dati, fornendo una clusterizzazione più robusta e significativa, come mostrato in Fig. 11.

C. Complessità Computazionale

Dal punto di vista computazionale, tutti e tre i metodi condividono la fase di costruzione del grafo e il calcolo della matrice Laplaciana, con complessità $O(n^2 \text{ neighbors})$ per la costruzione del grafo k -NN e $O(n^2)$ per il calcolo delle Laplaciane. La differenza principale risiede nella fase di decomposizione spettrale: il metodo non normalizzato e quello di Ng, Jordan e Weiss richiedono la risoluzione di un problema agli autovalori standard ($O(n^3)$ nel caso generale, $O(kn^2)$ per i primi k autovettori), mentre il metodo di Shi e Malik necessita della risoluzione di un problema generalizzato, computazionalmente più oneroso. Tuttavia, per grafi di medie dimensioni come quello considerato ($n = 25$), le differenze temporali risultano trascurabili.




Fig. 4. Gap Autovalori




Fig. 6. Gap Autovalori Jordan and Weiss




Fig. 5. Gap Autovalori Shi and Malik




Fig. 7. Clustering Un-Normalized

Shi & Malik (2000)




Fig. 8. Clustering Shi Malik

Ng, Jordan & Weiss (2002)




Fig. 9. Clustering Hordan Weiss

Unnormalized




Fig. 10. Clustering Un-Normalized

Shi & Malik (2000)




Fig. 11. Clustering Shi Malik

VI. CONCLUSIONI

Il presente lavoro ha fornito un'implementazione completa e un'analisi comparativa di tre varianti di spectral clustering: il metodo non normalizzato classico, l'approccio normalizzato di Shi e Malik (2000) basato sul problema agli autovalori generalizzato, e il metodo di Ng, Jordan e Weiss (2002) con normalizzazione delle righe. L'analisi teorica ed empirica ha evidenziato che, sebbene tutti i metodi condividano il principio fondamentale di sfruttare la struttura spettrale del grafo, le differenze nelle formulazioni matematiche conducono a comportamenti distinti nell'embedding dei dati e nelle partizioni risultanti principalmente con la presenza di grafi di grande dimensionalità.